

초기 열화 신호로 ESS 배터리 수명을 예측할 수 있는가?

MIT-Stanford 배터리 데이터셋 · 초기 100 Cycle · Cell 단위 회귀 분석

분석 목표

수명 종료까지 기다리지 않고 초기 충방전 신호로 장기 Cycle Life를 추정한다

입력

Cycle 1-100의 QD, Qdlin, IR, 온도,
충전시간과 충전 정책

목표값

cycle_life
Cell이 EOL에 도달하기까지의 총 Cycle 수

검증



Batch 1에서 모델 선택
Batch 2와 3은 외부 일반화 평가

ESS 적용 관점

교체 계획과 예방 정비를 위해 조기 위험 Cell을 선별할 수 있는지 검증

Batch별 수명 분포가 크게 다르다

분석 질문 · Batch 1에서 학습한 관계가 Batch 2와 3에서도 유지되는가?



핵심 발견

중앙값은 Batch 1 842.0, Batch 2 468.5, Batch 3 964.5 cycles다. Batch 2의 76.5%가 500 cycle 미만이다.

한 Batch의 높은 정확도만으로 현장 적용성을 판단할 수 없다


운전환경에 따라 수명 분포가 크게 달라진다. Batch 2·3에서 외부 일반화 성능을 확인해야 한다.

모델링 결정

Batch 1에서만 모델을 선택하고 튜닝한다. Batch 2는 단수명 영역 외부 테스트, Batch 3는 장수명 영역 추가 외부 테스트로 사용한다.

초기 용량 절대값만으로 장기 수명을 구분하기 어렵다

분석 질문 · 장수명 Cell과 단수명 Cell은 초기 열화 구간에서 어떻게 다른가?



분석 근거 **qd_10 vs cycle_life · Pearson r = 0.101**

핵심 발견

초기 QD 곡선은 상당 부분 겹치며 특정 Cycle의 용량 절대값과 수명의 관계가 약하다.

현재 용량이 비슷해도 남은 수명은 다를 수 있다

조기 위험 Cell을 구분하려면 단일 용량값보다 초기 열화 변화 속도와 곡선 변화를 추적해야 한다.

모델링 결정

qd_change, qd_slope와 전압별 곡선 변화인 $\Delta Q(V)$ 를 생성한다.

다음 분석



초기 10-100 Cycle의 미세한 Curve 변화는 수명을 설명하는가?

$\Delta Q(V)$ 는 초기 수명 구간에서 장기 수명 위험을 구분한다

분석 질문 · Cycle 10과 100 사이의 방전곡선 변화가 Cycle Life와 연결되는가?

$$\Delta Q_{100-10}(V) = Q_{100}(V) - Q_{10}(V)$$

QD 단일값 차이가 아니라 공통 전압 격자에서 계산한 Qdlin 곡선의 지점별 차이



Pearson

-0.886

Spearman

-0.880

초기 100 Cycle만으로 장기 열화 위험을 선별할 가능성이 있다


$\Delta Q(V)$ 변화가 큰 Cell일수록 수명이 짧아지는 경향이 강하다.

모델링 결정

$\log_dq_var$ 를 핵심 Feature 후보로 선정한다.

수명 예측에는 Cell 상태와 충전 운전조건이 함께 필요하다

분석 질문 · 충전 Protocol에 따라 Cycle Life 분포가 달라지는가?



핵심 발견

first_c_rate와 Cycle Life 사이에 Pearson $r = -0.577$ 의 연관이 관찰됐다.

Cell 상태가 같아도 운전조건이 다르면 기대수명은 달라질 수 있다

C-rate를 예측 변수와 검증 그룹에 포함하되, 관찰된 연관성을 인과관계로 단정하지 않는다.

모델링 결정



C-rate Feature를 포함하고 charging_policy를 고려한 그룹 분할을 적용한다.

충전 정책 분해

4.8C(80%)-3.6C → first_c_rate 4.8 / switch_soc 0.8 / second_c_rate 3.6

강한 ΔQ 신호에는 중복 정보도 함께 존재한다

분석 질문 · 어떤 초기 신호가 수명과 관련 있고, Feature끼리는 얼마나 중복되는가?



핵심 발견

ΔQ Feature들은 Cycle Life와 높은 상관을 보이지만 서로 강하게 연관된다.

강한 열화 신호를 많이 넣는 것보다 대표 지표를 잘 고르는 것이 중요하다

서로 비슷한 ΔQ Feature를 줄이고 정규화해 새로운 운전환경에서도 안정적인 모델을 구성한다.

모델링 결정

Feature Selection 또는 Regularization을 적용한다.

dq_std -0.896 · log_dq_var -0.886 · dq_range -0.884 · dq_min +0.883

EDA 결과를 Cell-level Feature로 구조화한다

한 Cell을 한 행으로 만들고 세 Batch에 동일한 Feature 생성 절차를 적용

EDA 관찰 결과	해석	생성 Feature
초기 QD 절대값의 구별력이 낮음	변화 속도와 누적 변화를 표현	qd_change · qd_slope
$\Delta Q(V)$ 와 수명의 관계가 강함	Early-life 열화 형태를 요약	log_dq_var · dq_min · dq_range
IR과 온도는 보조 신호	전기적·열적 상태 변화를 포함	ir_change · tavg_mean · tmax_max
충전 Protocol별 분포 차이	운전조건을 Cell 상태와 함께 반영	first_c_rate · switch_soc · second_c_rate
ΔQ Feature끼리 중복	대표 Feature 선택과 규제가 필요	Feature Selection · Regularization

출력 구조	cell_id · cycle_life · log_dq_var · qd_slope · ir_change · temperature · C-rate
-------	---

소규모 정형 데이터셋에 맞는 모델과 검증 구조

Feature와 하이퍼파라미터는 Batch 1에서만 결정하고 테스트 Batch는 최종 평가에만 사용

모델 후보

Linear Regression

기준 모델

선형 관계의 기준 성능

ElasticNet

주요 후보

다중공선성과 정규화

Gradient Boosting

비선형 비교

비선형 관계, 제한된 복잡도

딥러닝보다 전통 ML을 우선하는 이유

약 100개 Cell의 소규모 정형 데이터셋이다. 생성 Feature 기반 분석에서는 고복잡도 모델의 과적합 위험이 높다.

검증 구조

BATCH 1 학습 + 검증

모델 선택 · 스케일링 · 튜닝

BATCH 2 외부 테스트

단수명 영역 · 선택에 사용하지 않음

BATCH 3 추가 외부 테스트

장수명 영역 · 추가 일반화 검증

소규모 정형 데이터셋

전통 ML 우선

검증 결과로 최종 선택

목표값 $\log(\text{cycle_life})$ · 평가지표 역변환 후 원 Cycle 단위 MAPE

ESS 수명 예측에서 확인한 네 가지 핵심 결론

EDA 결과를 현장 적용 관점과 모델 검증 전략으로 연결

01 초기 예측

초기 Cycle 데이터로 장기 배터리 수명 위험을 조기에 구분할 가능성

02 절대값보다 추세

단일 용량값보다 초기 열화 변화 패턴을 추적하는 것이 중요

03 운전조건의 중요성

배터리 상태와 충전 운전조건을 함께 고려해야 함

04 일반화 검증의 중요성

다른 운전조건에서도 유지되는 외부 Batch 성능을 검증해야 함

초기 열화 패턴과 운전조건을 결합한 Cell 단위 Feature를 구축하고, 외부 Batch 일반화 성능을 중심으로 수명 예측 모델을 검증한다.