

초기 100 Cycle만으로 ESS 배터리 수명을 얼마나 일찍 예측할 수 있는가?

MIT-Stanford 배터리 데이터셋 · Cell 단위 Cycle Life 회귀

해결해야 할 문제

수명 종료 전, 초기 열화 신호로 장기 Cycle Life를 추정한다

왜 초기 100 Cycle인가?

EOL 전에 조기 위험 Cell을 가려낼 수 있는지 검증

X와 Y는 무엇인가?

X: QD, Qdlin, IR, 온도, 충전시간, 충전조건
Y: cycle_life


어떻게 검증하는가?

Batch 1에서 Feature·모델 결정
Batch 2·3은 외부 Test로 유지

조기 위험 Cell 선별 → 교체 계획 · 예방 정비 의사결정 지원

Cycle Life 분포는 Batch별 일반화 난이도를 먼저 알려준다

질문 · 150~2,300 Cycle 범위에서 장수명/단수명 비율과 짧은 Cell을 어떻게 볼 것인가?



수명 영역이 다른 **Random Split** 성능은 부족하다

Median: B1 842.0 / B2 468.5 / B3 964.5 cycles
B2의 76.5%가 500 cycle 미만

짧은 **Cell**은 제거 대상이 아니라 위험군 후보다


Cycle Life가 짧다는 이유만으로 삭제하지 않는다. 결측·측정 오류·물리적으로 불가능한 값만 제외 기준으로 둔다.

Batch 2·3은 외부 **Test**로 남긴다

Batch 1에서만 Feature 선택과 튜닝을 수행하고, Batch 2·3에서 수명 영역이 달라도 관계가 유지되는지 확인한다.

열화 곡선은 현재 용량보다 변화 속도를 보라고 말한다

질문 · QD 감소가 일정한지, 언제 가속되는지, 초기 구간에서 무엇을 Feature로 쓸 것인가?



단일 QD는 초기 수명 판별 신호로 약하다

qd_10 vs cycle_life · Pearson $r = 0.101$
한 시점의 Capacity만으로는 장기 수명 차이를 충분히 설명하지 못한다.

Knee point는 초기 예측에는 늦은 신호일 수 있다

후반 급격한 열화 시작점은 수명 종료에 가까워진 뒤 나타날 수 있다. 초기 100 Cycle 안의 변화가 더 중요하다.



변화 속도와 곡선 형태를 Feature로 바꾼다

qd_change · qd_slope로 “얼마나 빠르게 변했는가”를 표현하고, 전압 별 변화는 $\Delta Q(V)$ 로 확장한다.

$\Delta Q(V)$ 는 초기 100 Cycle 안에서 장기 열화 위험을 구분하는 핵심 신호다

질문 · Cycle 100 - Cycle 10의 Q(V) 곡선 차이가 장수명/단수명 Cell을 구분하는가?

$$\Delta Q_{100-10}(V) = Q_{100}(V) - Q_{10}(V) \quad \cdot \quad \text{QD 단일값 차이가 아니라 공통 전압 격자의 Qdlin 지점별 차이}$$




Pearson
r=-0.886

Spearman
 ρ =-0.880

초기 QD $r=0.101 \rightarrow \log \text{Var}(\Delta Q) r=-0.886$
수명 예측에 필요한 정보는
현재 용량보다 초기 열화 형태의 변화에 있다.
따라서 $\log_dq_var$ 를 대표 Early-life
degradation Feature로 사용한다.

C-rate는 수명 차이를 설명하는 운전조건 Feature다

질문 · 충전 Protocol별 평균 수명과 초기 열화 속도 차이를 모델 입력에 반영해야 하는가?



충전조건을 빼면 수명 차이의 일부를 놓칠 수 있다

Protocol별 Cycle Life 분포가 다르고, first_c_rate와 Cycle Life의 Pearson $r = -0.577$ 이 관찰됐다.

고속충전을 단독 원인으로 단정하지 않는다


C-rate는 인과 결론이 아니라 입력 필요성의 근거로 사용한다.
열화 속도(qd_slope, ΔQ)와 함께 본다.

모델 입력은 Cell 상태 + 운전조건 두 축으로 구성한다

Cell 상태: ΔQ , QD slope, IR, 온도
운전조건: first_c_rate, switch_soc, second_c_rate

예측력이 높은 Feature를 모두 넣는 것이 더 많은 정보를 뜻하지는 않는다

질문 · 어떤 초기 신호가 Cycle Life와 가장 관련 있고, Feature끼리는 얼마나 중복되는가?



가장 강한 신호는 ΔQ 계열이다

$dq_std -0.896 \cdot log_dq_var -0.886$
 $dq_range -0.884 \cdot dq_min +0.883$

강한 Feature가 동시에 중복 Feature다

ΔQ 계열은 Target과 강하게 연결되지만, 서로도 같은 초기 열화 현상을 반복한다.

대표 Feature + Regularization으로 제어한다

상관 상위 Feature를 모두 투입하지 않는다. log_dq_var 중심 후보와 ElasticNet으로 다중공선성을 다룬다.

5개 EDA 질문을 Feature 설계와 모델 전략으로 연결한다

각 Batch에서 관계가 유지되는 신호와 달라지는 신호를 구분해 모델 입력과 검증 구조를 결정

Q1 Cycle Life

중앙값
 $B1\ 842 \cdot B2\ 469 \cdot B3\ 965$
단수명: $B2\ 76.5\%$



Batch 1 선택·튜닝
Batch 2·3 외부 Test

Q2 QD 열화

$qd_slope - 수명\ r$
 $B1 + 0.10 \cdot B2 - 0.49$
 $B3 + 0.35 \cdot \text{방향}$
불일치



절대 QD·slope에
단독 의존하지 않음

Q3 ΔQ(V)

$\log_dq_var - 수명\ r$
 $B1 - 0.886 \cdot B2 - 0.910$
 $B3 - 0.742 \cdot \text{방향 유지}$



$\log_dq_var$
핵심 조기 열화
Feature

Q4 C-rate

$C_rate - 수명\ r$
 $B1 - 0.577 \cdot B2 + 0.138$
 $B3 - 0.039 \cdot \text{영향 차이}$



Cell 상태 + 운전조건
충전 정책 그룹 검증

Q5 상관관계

상위 신호
세 Batch 모두 ΔQ
계열
Feature끼리 강한
중복



대표 Feature 선택
ElasticNet·복잡도
제한

Batch마다 달라지는 관계와 공통으로 유지되는 신호를 구분해 Feature와 검증 전략을 결정한다.

EDA에서 확인한 문제를 그대로 모델 입력 설계로 바꾼다

Cell 1개 = Row 1개 · 모든 Batch에 동일한 Feature 생성 절차 적용

데이터가 말해준 문제	모델이 추가로 알아야 할 것	입력 Feature / 전략
Cycle Life 분포 차이	Batch 일반화 난이도 판단	Batch 1 선택·튜닝 / Batch 2·3 Test
초기 QD 절대값의 구분력 낮음	얼마나 빠르게 변했는가?	qd_change · qd_slope
ΔQ(V)가 수명과 강하게 연결	초기 열화 형태 변화 크기	log_dq_var · dq_min · dq_range
충전 Protocol별 수명 차이	어떤 조건에서 운전됐는가?	first_c_rate · switch_soc · second_c_rate
ΔQ Feature끼리 정보 중복	같은 신호 반복을 줄이는 방법	대표 Feature · Regularization

최종 Cell-level 입력: cycle_life · log_dq_var · qd_slope · ir_change · temperature · C-rate

확인된 데이터 특성에 맞춰 모델 후보와 검증 구조를 정한다

Regression 하나를 선택하고, Target은 $\log(\text{cycle_life})$ 로 학습한 뒤 원 Cycle 단위 MAPE로 평가

Linear Regression

Baseline

선형 기준 성능 확인

ElasticNet

Main Candidate

중복 Feature와 다중공선성을 L1+L2 정규화로 제어

Gradient Boosting

Non-linear Check

선형 모델이 놓칠 관계를 제한된 복잡도로 비교

왜 Regression인가?

Classification은 장/단수명 여부만 제공하지만, Regression은 예상 Cycle Life를 직접 제공한다. ESS에서는 predicted cycle_life - current cycle로 RUL 기반 의사결정에 연결할 수 있다.

왜 딥러닝이 우선이 아닌가?

약 100개 Cell의 소규모 정형 데이터다. 생성 Feature 기반 분석에서는 고복잡도 모델보다 재현성과 과적합 통제가 우선이다.

검증 구조: Batch 1에서 Feature 선택·Scaling·튜닝 → Batch 2 단수명 영역 외부 Test → Batch 3 장수명 영역 추가 Test