

초기 100 Cycle 데이터로 ESS 배터리 수명을 추정한다

MIT-Stanford Battery Dataset의 Batch 1·2·3을 비교해
초기 열화 신호와 운전조건을 모델 입력으로 설계한다.

Regression · Target: $\log(\text{Cycle Life})$

분석 범위




Batch 1
모델 선택과 튜닝

Batch 2·3
분포 비교와 외부 일반화 평가

Batch마다 수명 구간의 비중이 크게 다르다

질문: 단수명(<500), 중간(500~1,000), 장수명(>1,000) 셀은 Batch별로 어떻게 구성되는가?

단수명 중간 장수명



Batch	n	평균	중앙값	표준편차	<500	500~1,000	>1,000
B1	41	838.6	842.0	194.9	0 (0.0%)	31 (75.6%)	10 (24.4%)
B2	34	550.7	468.5	221.6	26 (76.5%)	5 (14.7%)	3 (8.8%)
B3	40	1,032.0	964.5	308.6	0 (0.0%)	21 (52.5%)	19 (47.5%)

확인된 차이

Batch 2는 76.5%가 500 Cycle 미만이다.

Batch 1과 3에는 500 Cycle 미만 셀이 없고, Batch 3의 장수명 비율은 47.5%다.

가장 짧은 셀

B1: 020 · 534 · 분석 포함

B2: 019 · 392 · 분석 포함

B3: 028 · 541 · 분석 포함







Batch 2의 396 Cycle 셀 1개는 Batch 1 연속 측정 셀로 제외했다.

MODELING DECISION

Feature와 모델은 Batch 1에서만 정하고, Batch 2·3은 서로 다른 수명 분포에서 일반화 성능을 확인하는 데 사용한다.

초기 기울기와 전체 수명 후반의 가속 구간은 같은 정보가 아니다

질문: QD는 일정하게 감소하는가, 그리고 급격한 열화가 시작되는 구간은 언제 나타나는가?



초기 10-100 Cycle

B1: 중앙 기울기 $-1.52e-5$ Ah/cycle
 B2: 중앙 기울기 $2.37e-5$ Ah/cycle
 B3: 중앙 기울기 $-1.66e-5$ Ah/cycle

초기 기울기와 수명의 Pearson r

B1: +0.10 B2: -0.49 B3: +0.35

전체 수명 기준 탐색적 Knee

B1: 중앙 549 Cycle
 B2: 중앙 323 Cycle
 B3: 중앙 754 Cycle


Knee는 11-cycle 중앙값 평할 후 시작점-EOL 직선에서 최대 이탈한 지점이다. 전체 수명을 사용한 사후 지표다.

MODELING DECISION

모델 입력에는 초기 qd_change와 qd_slope만 사용한다. Knee는 열화 메커니즘 설명용으로만 남기고 Feature에서 제외한다.

ΔQ 분산은 세 Batch에서 수명과 같은 방향의 강한 관계를 보인다

질문: Cycle 100-10의 전압별 용량 변화만으로 장단수명 셀을 구분할 수 있는가?



Batch별 관계

Pearson / Spearman

B1: -0.89 / -0.88

B2: -0.91 / -0.71

B3: -0.74 / -0.76

분산이 클수록 수명이 짧아지는 방향이 세 Batch에서 유지된다. Batch 2에서도 Pearson r이 가장 강하다.







Feature 선택은 Batch 1에서만 수행했고, Batch 2-3의 값은 관계가 다른 조건에서도 유지되는지 설명하기 위해 제시했다.

MODELING DECISION

$\log_{dq_var}$ 를 핵심 Early-life Feature로 두고, dq_min 과 dq_range 는 중복성을 확인한 뒤 함께 쓸지 결정한다.

C-rate와 수명의 관계는 Batch마다 방향과 크기가 달라진다

질문: 충전 Protocol과 초기 C-rate는 수명과 초기 열화 신호를 얼마나 설명하는가?



1차 C-rate ↔ Cycle Life

B1: $r = -0.58$

B2: $r = +0.14$

B3: $r = -0.04$

1차 C-rate ↔ 초기 QD 기울기

B1: $r = +0.16$

B2: $r = +0.23$

B3: $r = +0.76$

같은 C-rate라도 Protocol 구성과 Batch가 달라 관계가 바뀐다. 이 결과만으로 고속 충전이 수명 저하의 원인이라고 단정할 수 없다.

MODELING DECISION

first_c_rate, switch_soc, second_c_rate를 입력에 포함하고, charging_policy 단위로 분리해 같은 Protocol이 Train과 Validation에 섞이지 않게 한다.

강한 ΔQ 신호가 여러 Feature에 반복되어 다중공선성이 생긴다

질문: 수명과 연관된 신호는 Batch가 바뀌어도 유지되는가, 그리고 Feature끼리는 얼마나 겹치는가?

Feature $\leftrightarrow$ Cycle Life Pearson r

Feature	B1	B2	B3
log ΔQ 분산	-0.89	-0.91	-0.74
ΔQ 평균	+0.86	+0.75	+0.60
ΔQ 최솟값	+0.88	+0.81	+0.67
ΔQ 범위	-0.88	-0.79	-0.62
QD 기울기	+0.10	-0.49	+0.35
QD 10	+0.10	-0.39	+0.23
1차 C-rate	-0.58	+0.14	-0.04
IR 변화	+0.11	+0.07	-0.28

Batch 1 Feature 간 Pearson r

B1	log ΔQ 분산	ΔQ 평균	ΔQ 최솟값	ΔQ 범위	QD 기울기	QD 10	1차 C-rate	IR 변화
log ΔQ 분산	1.00	-0.93	-0.95	0.95	-0.01	0.17	0.66	-0.09
ΔQ 평균	-0.93	1.00	0.99	-0.99	0.13	-0.22	-0.58	0.09
ΔQ 최솟값	-0.95	0.99	1.00	-1.00	0.10	-0.20	-0.59	0.08
ΔQ 범위	0.95	-0.99	-1.00	1.00	-0.10	0.20	0.59	-0.08
QD 기울기	-0.01	0.13	0.10	-0.10	1.00	0.23	0.16	0.82
QD 10	0.17	-0.22	-0.20	0.20	0.23	1.00	0.08	0.26
1차 C-rate	0.66	-0.58	-0.59	0.59	0.16	0.08	1.00	0.13
IR 변화	-0.09	0.09	0.08	-0.08	0.82	0.26	0.13	1.00

중복이 큰 조합

ΔQ 최솟값
 ΔQ 범위 $r=-1.00$

ΔQ 평균
 ΔQ 범위 $r=-0.99$

ΔQ 평균
 ΔQ 최솟값 $r=0.99$

log ΔQ 분산
 ΔQ 최솟값 $r=-0.95$

log ΔQ 분산
 ΔQ 범위 $r=0.95$
강한 값이 많다는 사실보다 같은 신호가 여러 열에 반복된다는 점이 중요하다.

MODELING DECISION

Batch 1에서 대표 ΔQ Feature를 선별하고, 전체 후보를 쓸 때는 ElasticNet 정규화로 중복 신호의 계수를 안정화한다.

EDA에서 확인한 사실을 입력 변수와 검증 규칙으로 바꾼다

Cycle Life는 정답 Y이며 입력 X에 포함하지 않는다.

EDA에서 확인한 사실	모델에 반영한 판단	X 입력 후보 또는 검증 규칙
Batch 2는 단수명, Batch 3은 장수명 비중이 큼	Batch별 분포 이동을 외부 평가로 확인	Batch 1로 선택·튜닝, Batch 2·3은 고정 모델 평가
초기 QD 기울기의 관계가 Batch마다 달라짐	단일 기울기보다 변화량을 함께 사용	qd_change_10_100, qd_slope_10_100
log Var(ΔQ)는 세 Batch에서 수명과 강한 음의 관계	초기 열화 패턴의 핵심 신호로 채택	log_dq_var, dq_min, dq_range
C-rate 관계가 Batch마다 달라짐	셀 상태와 운전조건을 분리하지 않음	first_c_rate, switch_soc, second_c_rate
ΔQ 파생 변수끼리 $ r $ 가 0.95 이상	중복 변수를 선별하고 정규화 적용	대표 Feature 선택 + ElasticNet

X · 초기 1-100 Cycle의 ΔQ , QD, IR, 온도, 충전시간, C-rate 파생 Feature

Y · cycle_life
모델 Target · log(cycle_life)

MODELING DECISION

Knee와 수명 종료 이후 정보는 X에서 제외한다. 모든 입력 Feature는 Cycle 100 이내에서 계산한다.

작은 Tabular Dataset에 맞춰 단순 모델부터 비교한다

후보 모델은 Batch 1 Validation으로만 고르고, Batch 2·3 결과를 보고 Feature나 Hyperparameter를 바꾸지 않는다.

후보 모델	EDA와 연결되는 이유	역할
Linear Regression	작은 표형 데이터에서 기준 성능과 계수 방향 확인	Baseline
ElasticNet	ΔQ 파생 Feature의 높은 다중공선성을 L1/L2 정규화로 제어	Main Candidate
Gradient Boosting	ΔQ ·운전조건 사이의 비선형 관계가 선형 모델보다 유효한지 비교	Non-linear Check

검증 구조

Batch 1 · 모델 선택과 튜닝

charging_policy Group Split + Group CV
Feature 선택 · Scaling · Hyperparameter 탐색

Batch 2 · External Test

단수명 영역이 큰 조건
고정된 Pipeline의 일반화 평가

Batch 3 · Additional Test

장수명 영역이 큰 조건
같은 고정 Pipeline 추가 평가

MODELING DECISION

최종 모델은 Batch 1 Validation 결과로 결정한다. Batch 2·3은 고정된 모델이 다른 수명 분포에서도 유지되는지 확인하는 최종 평가다.

Batch 1 검증으로 Gradient Boosting을 선택했다

후보 모델 성능

모델	CV MAPE	Hold-out MAPE	역할
Linear Regression	16.95%	68.36%	선형 기준
ElasticNet	8.10%	20.58%	정규화 비교
Gradient Boosting	10.45%	8.48%	최종 선택

선택 기준

Batch 1 Hold-out MAPE를 우선하고 CV MAPE는 동률 비교에만 사용했다.

Batch 2와 Batch 3 결과는 모델이나 Feature를 다시 고르는 데 사용하지 않았다.


최종 모델

Gradient Boosting Regressor

learning_rate 0.1 max_depth 1 n_estimators 100

얇은 Tree로 비선형 관계를 반영하면서 작은 데이터셋의 모델 복잡도를 제한했다.

내부 검증 8.48%, Batch 2 외부 테스트 37.01%



성능 차이

+28.53%p

Valid와 Batch 2 Test의 차이

+27.91%p

원논문 Target 9.1%와 Batch 2의 차이

Batch 1 내부 성능만으로 외부 Batch의 일반화 성능을 판단하기 어렵다.

Batch 2는 단수명 분포가 많아 학습 범위를 벗어난 외삽 오류를 확인하는 핵심 외부 테스트다.

Batch 2 단수명 Cell에서 과대예측이 집중됐다

평가 Batch	MAPE	중앙 APE	평균 편향	과대예측 비율
Batch 2	37.01%	34.77%	+148.6 Cycle	88.2%
Batch 3	16.93%	13.32%	-206.2 Cycle	17.5%

최대 오류 Cell

Batch2_cell_006

실제 393 Cycle
예측 685 Cycle
APE 74.2%

확인된 원인

Batch 1에는 500 Cycle 미만 Cell이 없지만 Batch 2의 76.5%가 단수명 Cell이다.

모델이 학습하지 못한 영역을 외삽하면서 수명을 길게 예측했다. 개선하려면 단수명 학습 Cell과 OOD 경고가 필요하다.

Test 결과를 본 뒤 Feature나 하이퍼파라미터를 다시 선택하지 않았다.

초기 열화 신호는 유효했지만 배치 일반화가 남았다

01 초기 예측

10~100 Cycle의 $\Delta Q(V)$ 로 장기 수명과 관련된 열화 신호를 포착했다.

02 변화 추세

단일 QD 값보다 초기 용량 변화량과 ΔQ 분산이 수명을 더 잘 설명했다.

03 운전조건

충전조건이 Batch마다 달라 Cell 상태와 운전정보를 함께 봐야 한다.

04 일반화 검증

Batch 2의 큰 오류는 학습 분포와 다른 단수명 영역에서 발생했다.

최종 모델링 방향

초기 열화 패턴과 운전조건을 결합하고, 외부 Batch 성과 OOD 여부를 함께 확인한다.